

MOPD Phase 4-1 — 학습 중 교사 task vector merge의 proxy signal

Qwen3-4B-OT3 · 5-domain MOPD(uniform merge arm) · 2026-09-18 22:56 기준 · fork 세션 작업

0. 요약

- 질문:** uniform merge로 시작한 MOPD에서, 학습이 안 되는 도메인에 그 교사의 task vector τ_d 를 학습 도중 추가로 merge해 SFT warm-up을 대신하려 한다. 어느 도메인을, 얼마나 merge할지를 정하는 proxy signal은 무엇인가.
- 측정한 signal:** (W) weight-space — 갱신·ckpt task vector와 τ_d 의 $\cos$ / OLS 투영 계수 / 부호 일치율 / SVD 부분공간 에너지 / SAR; (L) function-space — 교사 샘플 NLL의 $\theta + \lambda \tau_d$ line search; (G) gradient — warm-up 방향 $-\nabla \text{NLL}_d$ 와 τ_j 의 정렬. (L)·(G)는 job 578646 결과가 나오면 3절에 추가.
- 발견 1 (전제 성립):** OPD의 이동은 자기 교사 τ 와만 정렬된다(부호 일치율 0.64-0.88 vs 다른 교사 0.47-0.52). 200 step에 τ_d 까지 간 비율은 fin 0.17·if 0.14인데 law 0.055·tau 0.026·med 0.007 — OPD 이동량은 도메인과 무관하게 $\|\Delta\| \approx 1.3$ -2.2로 고정이라, τ 가 큰 SFT 교사 도메인(med 30.2, law 7.3, tau 7.5)은 학습만으로 못 따라간다. merge가 warm-up을 대체해야 하는 이유의 정량 근거.
- 발견 2 (얼마나):** 끌림(갱신과 τ_d 의 정렬)은 이미 merge된 계수의 감소함수이고 0을 지나는 계수가 있다 — 그 지점이 MOPD가 그 방향으로 더 움직이려 하지 않는 평형 계수. 2-dom에서 med·IF 모두 ≈ 0.8 , 5-dom에서 med ≈ 0.5 , tau ≈ 0.4 (0.5는 과잉: 끌림 음수), law ≈ 0.3 (med 0.5와 함께). 끌림 0 계수는 in-domain 최적의 **상한**이고 OOD 비용(LCB·CaseHOLD)은 계수와 함께 커진다.
- 발견 3 (어느 도메인):** 끌림의 절대 크기는 도메인 간 비교가 안 된다(IF가 가장 크지만 merge가 필요 없다). 대신 **끌림이 학습 중 감소하지 않는 도메인**(med·law·tau)이 벤치마크 정제 도메인과 일치하고, 단일 도메인 OPD·2-dom grid에서도 같은 패턴이 다.
- 발견 4:** 임베딩(=tied lm_head)만은 OPD 갱신이 SFT 교사의 변화와 반대 방향이다($\cos -0.08/-0.09/-0.19$ @u5 ck100). 나머지 252개 행렬은 음의 정렬이 0-3%. 임베딩 제외 merge를 후보에 넣었다.

1. Weight-space alignment signal (63 모델 × 398 텐서)

표 1. 교사 task vector $\tau_d = \text{teacher}_d - \text{OT3 base}$ 의 기하

교사	$\ \tau\ $	0 아닌 좌표	stable rank(평균)	상위 64 특이방향 에너지	$\cos \tau_{\text{med}}$	$\cos \tau_{\text{law}}$	$\cos \tau_{\text{fin}}$	$\cos \tau_{\text{if}}$	$\cos \tau_{\text{tau}}$
med	30.2	89%	60	0.28	+1.000	+0.100	-0.019	-0.004	+0.040
law	7.3	66%	14	0.51	+0.100	+1.000	-0.018	-0.002	+0.052
fin	2.3	100%	13	0.45	-0.019	-0.018	+1.000	+0.009	-0.030
if	2.5	100%	13	0.44	-0.004	-0.002	+0.009	+1.000	-0.007
tau	7.5	66%	18	0.42	+0.040	+0.052	-0.030	-0.007	+1.000

SFT 교사(med·law·tau)는 RL 교사(fin·if)보다 3-13배 멀리 있고, 서로 거의 직교(med·law만 0.10). RL 교사는 fp32로 저장되어 좌표가 전부 0이 아님.

표 2. 전제 검증 — base에서 시작한 단일 도메인 OPD ck200의 이동(ckpt – base)은 자기 교사 τ 와만 정렬되는가

run	$\ \text{이동}\ $	$\cos(\text{자기 교사})$	$\cos(\text{다른 교사 4개})$	부호 일치율(자기)	부호 일치율(다른)	OLS 계수(τ 도달 비율)	부분공간 r64 농축	SAR(자기)
단일 OPD med	2.20	+0.109	+0.005 - +0.125	0.635	0.511 - 0.635	0.007	9.3×	0.882
단일 OPD law	1.76	+0.228	+0.005 - +0.021	0.778	0.508 - 0.518	0.055	12.1×	0.904
단일 OPD fin	1.34	+0.291	-0.005 - +0.002	0.880	0.491 - 0.505	0.170	10.9×	0.921
단일 OPD if	1.45	+0.243	-0.001 - +0.004	0.816	0.495 - 0.512	0.141	11.1×	0.911
단일 OPD tau	1.54	+0.127	-0.005 - +0.010	0.710	0.474 - 0.520	0.026	9.9×	0.906

부호 일치율 = τ_d 크기 상위 20% 좌표에서 이동의 부호가 τ_d 와 같은 비율(우연 0.5). 농축 = τ_d 상위 64 특이방향에 들어간 이동 에너지 ÷ 무작위 기대치(64/2560). SAR = τ_d 가 이동 벡터의 95%-에너지 부분공간에 들어가는 비율(대비가 가장 약함).

표 3-1. 끌림(MOPD 갱신 ck200 – merge init 과 τ_d 의 정렬) vs 이미 merge된 계수 — 2-dom med+IF grid

arm	med 계수	med 끌림 $\cos$	med 부호 일치	IF 계수	IF 끌림 $\cos$	IF 부호 일치
2-dom r20	0.2	+0.074	0.609	0.8	-0.001	0.500
2-dom r40	0.4	+0.061	0.593	0.6	+0.042	0.569

arm	med 계수	med 끌림 cos	med 부호 일치	IF 계수	IF 끌림 cos	IF 부호 일치
2-dom r60	0.6	+0.028	0.544	0.4	+0.092	0.639
2-dom r80	0.8	-0.002	0.498	0.2	+0.131	0.684

계수가 클수록 끌림이 단조 감소하고 0.8 부근에서 0을 지난다. 같은 arm의 MedQA: init 73.4/75.6/77.4/80.0 → ck200 76.0/76.7/79.4/80.3 — 끌림이 0인 r80만 학습으로 더 오르지 않는다.





표 3-2. 같은 관계 — 5-dom arm 4개(ck150까지의 누적 갱신)

arm	계수 med/law/fin/if/tau	cos med	cos law	cos fin	cos if	cos tau	부호 med	부호 law	부호 fin	부호 if	부호 tau
base init (계수 0)	0/0/0/0/0	+0.033	+0.109	+0.047	+0.113	+0.073	0.538	0.623	0.570	0.653	0.603
uniform	.2/.2/.2/.2/.2	+0.022	+0.067	+0.028	+0.085	+0.059	0.522	0.569	0.544	0.622	0.585
mix33211	.3/.2/.1/.1/.3	+0.014	+0.041	+0.031	+0.091	+0.037	0.512	0.538	0.549	0.629	0.558
ns55322	.5/.3/.2/.2/.5	-0.003	-0.010	+0.020	+0.064	-0.032	0.491	0.474	0.532	0.595	0.492

med는 계수 0.5에서 0, tau는 0.5에서 음수(과잉), law는 med .5+law .3에서 ≈ 0 (med가 law 방향으로 0.41배 누설). fin-if는 계수 범위가 좁아 기울기 추정 불확실.

표 4. uniform arm의 25-step 구간별 플림

구간	$\ \Delta\ $	cos med	cos law	cos fin	cos if	cos tau	OLS med	OLS law	OLS fin	OLS if	OLS tau
init $\rightarrow$ ck25	0.339	+0.002	+0.006	+0.007	+0.019	+0.004	+0.0000	+0.0002	+0.0011	+0.0026	+0.0002
ck25 $\rightarrow$ ck50	0.590	+0.006	+0.019	+0.014	+0.046	+0.022	+0.0001	+0.0014	+0.0037	+0.0108	+0.0017
ck50 $\rightarrow$ ck75	0.687	+0.008	+0.026	+0.012	+0.049	+0.023	+0.0001	+0.0023	+0.0039	+0.0135	+0.0020
ck75 $\rightarrow$ ck100	0.740	+0.009	+0.031	+0.011	+0.036	+0.026	+0.0001	+0.0030	+0.0040	+0.0108	+0.0024
ck100 $\rightarrow$ ck125	0.762	+0.011	+0.032	+0.010	+0.027	+0.028	+0.0002	+0.0032	+0.0037	+0.0083	+0.0027
ck125 $\rightarrow$ ck150	0.765	+0.012	+0.033	+0.010	+0.022	+0.028	+0.0002	+0.0032	+0.0038	+0.0068	+0.0027
ck150 $\rightarrow$ ck175	0.767	+0.012	+0.030	+0.010	+0.018	+0.028	+0.0002	+0.0029	+0.0036	+0.0057	+0.0027
ck175 $\rightarrow$ ck200	0.769	+0.013	+0.028	+0.009	+0.015	+0.025	+0.0002	+0.0028	+0.0033	+0.0048	+0.0025

if-fin은 감쇠(벤치도 ck50-150에 교차 수준), med-law-tau는 감쇠 없음(벤치 med 54%-law 53% @ck150). 단일 도메인 OPD에서도 med-tau만 후반 플림이 증가.

2. merge 직후 성능 (13벤치, tau2 제외)

표 5-1. 핵심 열

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	§ (4도메인)
base OT3	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	0%
teacher med	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	-
teacher law-sft	63.4	73.6	59.6	39.4	25.0	47.5	43.3	46.7	45.8	42.5	-
teacher fin	68.0	60.4	75.3	32.9	24.7	53.8	45.0	53.8	50.8	49.0	-
teacher if	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	-
uniform init (merge 직후)	71.9	66.4	69.7	51.2	34.7	60.4	53.8	60.8	58.3	1.7	41%
uniform ck50	71.9	64.5	73.1	71.5	55.0	65.8	57.9	64.2	62.6	53.6	57%
uniform ck100 (merge 전 기준)	73.8	66.5	73.8	72.5	56.7	64.2	61.2	61.2	62.2	52.4	68%
uniform ck150	74.0	68.2	75.5	77.3	58.0	66.2	55.8	59.6	60.6	55.5	77%
uniform ck200	74.2	69.1	74.5	79.1	57.7	62.1	57.5	62.1	60.6	54.2	78%
ns55322 ck100	77.3	69.2	72.5	72.1	56.3	64.6	55.8	59.2	59.9	50.0	79%
ns55322 ck200	76.9	69.5	73.1	62.5	54.3	60.8	50.8	57.5	56.4	51.9	76%
uniform ck100 + law 0.1	71.9	67.5	75.2	73.4	56.7	68.3	57.1	60.8	62.1	50.2	68%
uniform ck100 + law 0.3	70.9	70.7	73.4	74.9	52.7	64.2	55.4	59.6	59.7	51.6	69%
uniform ck100 + law 0.5	68.4	73.4	71.6	71.0	57.0	65.4	54.2	57.5	59.0	48.8	67%
uniform ck100 + med 0.1	72.8	67.3	74.4	72.5	55.7	62.5	58.3	56.2	59.0	52.2	68%
uniform ck100 + med 0.3	77.2	66.9	74.9	75.0	57.0	63.3	54.6	57.5	58.5	51.4	79%
uniform ck100 + med 0.3 + law 0.1	75.3	68.8	72.8	74.5	58.3	63.3	54.2	57.5	58.3	49.3	76%
uniform ck100 + med 0.3 + law 0.1 (텐서별 정렬 비례)	76.7	68.4	73.9	74.9	57.0	64.2	51.2	55.4	56.9	48.8	79%
uniform ck100 + med 0.5	77.4	66.6	72.0	70.6	58.3	62.1	50.8	55.0	56.0	50.3	73%
uniform ck50 + med 0.3 + law 0.1	74.9	67.5	71.8	70.6	51.0	65.0	51.7	59.6	58.8	45.2	66%
uniform ck200 + med 0.3 + law 0.1	75.5	70.1	73.8	76.5	61.0	63.8	55.8	56.7	58.8	50.2	82%
ns55322 ck200 + med 0.3	79.3	68.5	72.7	65.2	55.3	58.3	55.4	52.9	55.6	48.1	79%
5교사 uniform merge (임베딩 제외), 학습 없음	70.9	65.7	67.8	52.5	33.0	64.2	55.8	54.2	58.1	2.8	34%

프로토콜: 전 벤치 T=1.0 / top_p 1.0 / top_k 해제(학습 롤아웃과 동일), in-domain 26,624 tok, OOD 32,768 tok, AIME avg@8. § = (학생-base)/(교사-base)의 4도메인(med-law-fin-IF) 평균. 후보 행 = ckpt + Σλ·τ (학습 없음). '-' = 평가 진행 중.

표 5-2. OOD-safety 열 (↓ = 낮을수록 좋음, 평균에 넣지 않음)

모델 (ckpt)	GPQA	HarmBench ASR↓	Sycophancy↓	TruthfulQA MC2
base OT3	30.3	86.0	78.3	51.0
uniform init (merge 직후)	40.3	57.0	79.8	51.0
uniform ck50	45.8	56.7	79.6	49.2
uniform ck100 (merge 전 기준)	38.9	65.0	79.5	48.4
uniform ck150	33.1	73.3	79.5	48.5

모델 (ckpt)	GPQA	HarmBench ASR↓	Sycophancy↓	TruthfulQA MC2
uniform ck200	37.5	73.7	79.6	48.2
ns55322 ck100	48.7	55.0	79.2	49.7
ns55322 ck200	44.2	49.7	79.3	49.8
uniform ck100 + law 0.1	40.9	64.3	79.7	48.3
uniform ck100 + law 0.3	49.0	64.7	80.1	47.8
uniform ck100 + law 0.5	46.0	70.7	80.6	46.9
uniform ck100 + med 0.1	44.3	60.7	79.7	48.3
uniform ck100 + med 0.3	48.6	63.7	79.6	48.2
uniform ck100 + med 0.3 + law 0.1	49.1	64.3	79.8	47.9
uniform ck100 + med 0.3 + law 0.1 (텐서별 정렬 비례)	52.3	63.3	79.8	47.3
uniform ck100 + med 0.5	47.5	61.7	79.1	47.9
uniform ck50 + med 0.3 + law 0.1	47.7	58.3	79.6	48.9
uniform ck200 + med 0.3 + law 0.1	49.7	67.7	79.7	47.3
ns55322 ck200 + med 0.3	48.0	50.3	78.5	49.5
5교사 uniform merge (임베딩 제외), 학습 없음	38.1	56.0	79.7	50.6

표 5-3. 도메인별 진행률

모델	med	law	fin	IF
uniform init (merge 직후)	35%	37%	61%	32%
uniform ck50	35%	20%	85%	88%
uniform ck100 (merge 전 기준)	52%	38%	89%	92%
uniform ck150	54%	53%	101%	100%
uniform ck200	55%	61%	95%	101%
ns55322 ck100	83%	62%	81%	91%
ns55322 ck200	79%	64%	85%	76%
uniform ck100 + law 0.1	35%	47%	99%	93%
uniform ck100 + law 0.3	27%	75%	87%	88%
uniform ck100 + law 0.5	5%	98%	74%	90%
uniform ck100 + med 0.1	43%	45%	93%	90%
uniform ck100 + med 0.3	82%	42%	97%	95%
uniform ck100 + med 0.3 + law 0.1	65%	58%	83%	97%
uniform ck100 + med 0.3 + law 0.1 (텐서별 정렬 비례)	77%	55%	90%	95%
uniform ck100 + med 0.5	83%	39%	77%	92%
uniform ck50 + med 0.3 + law 0.1	62%	47%	76%	81%
uniform ck200 + med 0.3 + law 0.1	67%	69%	90%	103%
ns55322 ck200 + med 0.3	100%	55%	82%	81%
5교사 uniform merge (임베딩 제외), 학습 없음	27%	31%	49%	31%

3. Function-space signal — 교사 샘플 NLL (job 578646, 후보 189개)

probe d = 도메인 d 학습 풀의 고정 부분집합(96문항: tau 64, math 48)에 대한 교사 d의 샘플(T=1.0, k=1, 필터 없음). NLL_d(θ) = 그 샘플의 토큰 평균 NLL = forward KL(교사 || θ) + 상수 = SFT warm-up이 줄이는 바로 그 손실. math probe는 base 모델 샘플(retention 지표).

표 L1. proxy 타당성 — 기존 모델 47개에서 probe NLL_d 와 벤치마크 점수_d 의 상관

도메인	모델 수	Pearson	Spearman	NLL 범위	점수 범위
med	48	-0.85	-0.93	0.29 - 1.33	63.4 - 80.3
law	48	-0.73	-0.85	0.34 - 1.33	44.8 - 73.6
fin	48	-0.91	-0.83	0.65 - 1.08	52.5 - 75.6
if	48	-0.93	-0.81	0.19 - 1.09	27.9 - 69.9
math	48	-0.59	-0.31	0.58 - 0.83	42.1 - 63.3

in-domain 4개는 순위 상관 −0.82 - −0.93. math probe는 약함(−0.31): 47개 모델의 math 점수 범위가 좁고 AIME 잡음이 큼. IF·fin은 포화/절벽형(IF는 NLL ≤0.6이면 점수 포화, fin은 0.78-0.85에 절벽) → 선형이 아니라 단조(isotonic) 사상으로 예측.

표 L2. 기준 NLL (nats/token) — 행 = 모델, 열 = probe

모델	med	law	fin	if	tau	math
base	1.209	1.126	0.805	0.832	1.063	0.584
T_med	0.291	0.661	1.081	1.088	1.208	0.827
T_law	0.770	0.341	0.930	0.964	1.130	0.682
T_fin	1.252	1.183	0.648	0.896	1.112	0.629
T_if	1.326	1.327	0.875	0.191	1.129	0.626
T_tau	1.192	1.136	0.917	0.912	0.325	0.671
u5_init	0.757	0.615	0.781	0.722	0.746	0.616
u5_ck50	0.727	0.578	0.750	0.523	0.718	0.621
u5_ck100	0.691	0.509	0.708	0.297	0.663	0.620
u5_ck150	0.664	0.469	0.687	0.254	0.621	0.619
u5_ck200	0.646	0.448	0.676	0.239	0.596	0.618
ns5_init	0.490	0.514	0.949	0.901	0.583	0.760
ns5_ck100	0.451	0.449	0.742	0.382	0.461	0.661
ns5_ck200	0.429	0.418	0.701	0.308	0.417	0.647
b5_ck150	1.006	0.847	0.687	0.240	0.874	0.615
u5_ck200: base→교사 NLL 격차 해소율	61%	86%	82%	93%	63%	-

대각(교사 자신의 NLL)이 하한. uniform arm은 학습으로 IF·fin·law의 격차를 대부분 닫지만 med·tau는 60% 남짓에서 멈춘다. math(retention)는 uniform arm에서 평탄(0.616-0.620), ns55322는 0.647-0.760으로 나뉨.

표 L3. line search — 자기 probe NLL을 최소로 하는 λ (괄호 = ΔNLL×1000), uniform arm의 ckpt별

시작 ckpt	+λ·τ_med	+λ·τ_law	+λ·τ_fin	+λ·τ_if	+λ·τ_tau
u5_init	λ*=0.50 (-393)	λ*=0.50 (-247)	λ*=0.50 (-56)	λ*=0.50 (-143)	λ*=0.50 (-352)
u5_ck50	λ*=0.50 (-357)	λ*=0.50 (-191)	λ*=0.50 (-41)	λ*=0.30 (-35)	λ*=0.50 (-332)
u5_ck100	λ*=0.50 (-301)	λ*=0.50 (-98)	λ*=0.50 (-16)	λ*=0.10 (-2)	λ*=0.50 (-268)

시작 ckpt	+λ·τ_med	+λ·τ_low	+λ·τ_fin	+λ·τ_if	+λ·τ_tau
u5_ck150	λ*=0.50 (-257)	λ*=0.30 (-60)	λ*=0.30 (-6)	λ*=0.10 (-0)	λ*=0.50 (-215)
u5_ck200	λ*=0.50 (-228)	λ*=0.30 (-44)	λ*=0.30 (-4)	λ*=0.00 (+0)	λ*=0.50 (-181)

grid λ∈{0.1,0.2,0.3,0.5}(ck100의 med-low는 0.05-0.7). IF 방향은 학습이 진행되며 소진된다(λ* 0.5→0.3→0.1→0.1→0) — weight-space의 '클리프 감쇠'와 같은 그림. med-tau는 끝까지 λ*≥0.5, low는 0.5→0.3으로 줄고 이득도 −247→−44로 감소.

표 L4. 간섭 행렬 — uniform ck100에 더했을 때 각 probe의 ΔNLL×1000 (음수 = 개선)

merge	med	low	fin	if	tau	math
+0.3·τ_med	-226	-13	+66	+158	+49	+62
+0.3·τ_low	-35	-89	+33	+84	+17	+24
+0.3·τ_fin	+2	+3	-10	+5	+1	+7
+0.3·τ_if	+17	+14	+6	+45	+9	+8
+0.3·τ_tau	+10	+9	+22	+48	-165	+19
+0.3 med +0.1 low	-222	-30	+86	+212	+62	+76
” (임베딩 제외)	-216	-32	+68	+207	+52	+62
+0.3 med +0.3 low	-196	-29	+149	+356	+108	+120
+0.3 med +0.1 low +0.2 tau	-205	-16	+118	+275	-75	+103
전 교사 +0.3	-122	+58	+222	+547	-44	+206
” (임베딩 제외)	-123	+49	+165	+534	-52	+160

SFT 교사 τ를 더하면 자기 도메인은 크게 좋아지지만 IF probe가 가장 크게 나빠진다(+158 / +84). 임베딩 제외는 자기 도메인 이득을 거의 유지(−222→−216)하면서 fin·tau·math 손상을 약 20% 줄인다.

4. Gradient signal — warm-up 방향(−∇NLL_d)과 교사 task vector의 정렬 (job 578690)

$\mathbf{g}_d = \nabla \text{NLL}_d(\theta)$ (probe d의 48개 시퀀스, fp32). $\langle \mathbf{g}_d, \boldsymbol{\tau}_j \rangle$ = 교사 j를 단위 계수만큼 merge할 때 도메인 d probe NLL의 1차 변화(음수 = 이득). $\cos(-\mathbf{g}_d, \boldsymbol{\tau}_j)$ 는 방향만 본 값.

표 G1. merge Jacobian @ uniform ck100 — 행 = probe 도메인, 열 = merge하는 교사 (nats/token per unit λ)

	τ_{med}	τ_{law}	τ_{fin}	τ_{if}	τ_{tau}	$\cos(-\mathbf{g}_d, \boldsymbol{\tau}_d)$
probe med	-0.914	-0.250	+0.008	+0.081	-0.004	+0.0078
probe law	-0.251	-0.625	+0.013	+0.056	-0.014	+0.0395
probe fin	+0.163	+0.134	-0.141	+0.035	+0.071	+0.0265
probe if	+0.283	+0.191	+0.019	-0.281	+0.088	+0.0304
probe tau	+0.130	+0.015	-0.009	+0.057	-1.217	+0.0147
probe math	+0.113	+0.070	+0.026	+0.037	+0.036	-

대각 = 자기 도메인 이득, 비대각 양수 = 간섭. med↔law는 서로 돕고(−0.25), SFT 교사 τ는 IF·fin·math를 해친다. cos는 0.008-0.04로 작고 도메인 간 크기 비교가 안 된다 — 비교 가능한 단위는 방향도함수(단위 merge 계수당 이득).

표 G2. 자기 도메인 1차 이득 $\langle \mathbf{g}_d, \boldsymbol{\tau}_d \rangle$ 의 학습 중 변화와, 학습이 $\boldsymbol{\tau}_d$ 방향으로 공급하는 속도

도메인	init	ck100	ck200	init→ck200 감쇠	학습의 공급 속도 (OLS 계수/step @ck100)	line search 최적 λ^* @ck100 ($\Delta \text{NLL} \times 1000$)	학습만으로 λ^* 만큼 가는 데 필요한 step
med	-1.073	-0.914	-0.802	25%	0.00001	$\lambda^*=0.50$ (-301)	79,500 step
law	-1.034	-0.625	-0.393	62%	0.00012	$\lambda^*=0.50$ (-98)	4,090 step
fin	-0.289	-0.141	-0.073	75%	0.00016	$\lambda^*=0.50$ (-16)	3,220 step
if	-0.630	-0.281	-0.060	90%	0.00038	$\lambda^*=0.10$ (-2)	260 step
tau	-1.381	-1.217	-0.872	37%	0.00010	$\lambda^*=0.50$ (-268)	4,910 step

마지막 열 = $\lambda^* \div$ 공급 속도: 학습만으로 그 방향의 최적점까지 가는 데 걸리는 시간. if는 수백 step(학습이 해결), med는 수만 step(불가능 → merge 대상), law·tau는 수천 step. 벤치마크 정제 순서(med·law 정제, fin·IF 도달)와 일치. IF는 1차 이득(−0.28)이 남아 보여도 곡률이 커서 line search 최솟값은 $\lambda \approx 0.1 \rightarrow$ 1차 정보만으로 양을 정하면 과잉 merge.

4-b. 구현 합정 — bf16 반올림이 작은 merge를 지운다 (job 578698, 578705)

bf16 ckpt는 격자 위에 정확히 놓여 있어, 격자 반 스텝($\lvert\theta\rvert\approx 0.02$ 에서 $\approx 6e-5$)보다 작은 원소 증분은 round-to-nearest에서 0이 된다. τ 의 원소 rms는 med 4.8e-4, law-tau 1.2e-4, fin-if 3.6e-5라 SFT 교사의 작은 λ , RL 교사의 거의 모든 λ 가 해당한다. 아래 '남은 계수' = (merge된 모델 – 시작 ckpt)를 교사 τ 5개에 OLS 투영한 계수.

표 R1. 의도한 merge vs bf16 저장 후 실제로 남은 계수 (uniform ck100 기준)

의도	남은 계수	바뀐 weight 비율	변화 중 의도한 방향의 비율(R^2)
med 0.10	med 0.083	40%	0.68
med 0.30	med 0.303	72%	0.94
med 0.50	med 0.500	81%	0.96
law 0.10	law 0.026	12%	0.20
law 0.30	law 0.223	34%	0.56
law 0.50	law 0.500	50%	0.71
if 0.30	if 0.092	13%	0.23
fin 0.30	fin 0.087	11%	0.22
med 0.30 + law 0.10	med 0.301, law 0.091	71%	0.94
전 교사 0.30	med 0.301, law 0.303, fin 0.280, if 0.278, tau 0.301	74%	0.95

단독 law 0.1은 0.026만 남지만 med 0.3과 함께 넣으면 0.091이 남는다 — 큰 τ_{med} 증분이 dither 역할. 학습 중에는 fp32 master weight의 잔차가 같은 역할을 하므로, '조금씩 merge'는 fp32 master에서 하거나 편향 없는 stochastic rounding(SR)으로 저장해야 한다([tmp/phase4/sr_bf16.py](#)). 자체 검 증: 남은 계수 RTN 0.33 vs SR 1.00).

표 L6. line search 재측정 — 자기 probe $\Delta\text{NLL}\times 1000$, 칸 = SR / round-to-nearest, uniform ck100

merge	$\lambda=0.05$	$\lambda=0.1$	$\lambda=0.2$	$\lambda=0.3$	$\lambda=0.5$	SR 기준 최적
+ $\lambda\cdot\tau_{\text{med}}$	-44 / -25	-86 / -72	-162 / -157	-224 / -226	-301 / -301	$\lambda^* = 0.50$
+ $\lambda\cdot\tau_{\text{law}}$	-27 / -4	-49 / -16	-81 / -50	-99 / -89	-98 / -98	$\lambda^* = 0.30$
+ $\lambda\cdot\tau_{\text{fin}}$	-6 / -	-10 / -2	-16 / -6	-18 / -10	-7 / -16	$\lambda^* = 0.30$
+ $\lambda\cdot\tau_{\text{if}}$	-0 / -	+22 / -2	+117 / +5	+256 / +45	+577 / +262	$\lambda^* = 0.05$
+ $\lambda\cdot\tau_{\text{tau}}$	-39 / -	-77 / -24	-144 / -80	-200 / -165	-268 / -268	$\lambda^* = 0.50$

SR로 재면 곡선이 매끈한 불룩형이 된다: law는 $\lambda\approx 0.3-0.5$ 에서 평탄한 최솟값(-98), fin은 $\lambda\approx 0.3$ 에서 작은 최솟값(-18), IF는 어떤 λ 에서도 악화(+22@0.1, +256@0.3) — ck100의 학생은 τ_{if} 방향으로 이미 최적점을 지났다. round-to-nearest는 이 악화를 가려서(+45@0.3) 잘못된 안심을 준다. seed를 바꿔도 값은 ± 0.2 이내.

5. 용량·반응 — merge 직후 성능 vs 실제로 들어간 계수 (uniform ck100, 학습 없음)

괄호 = merge 전 ckpt와 같은 문항끼리 쌍체 비교한 차이 ± 95% CI(문항당 표본 1개; AIME는 90문항의 avg@8 차이). § 차이의 95% CI는 약 ±7점.

표 D1. τ_{med}

uniform ck100에 더한 것	bfi6에 남은 계수	MedQA	CaseHOLD	FinQA	IFEval	IFBench	math(AIME 평균)	LCB v6	GPQA	§
(merge 전)	0	73.8	66.5	73.8	72.5	56.7	62.2	52.4	38.9	68%
+0.1· τ_{med}	0.083	72.8 (-0.9 ± 2.3)	67.3 (+0.7 ± 1.1)	74.4 (+0.6 ± 1.8)	72.5	55.7	59.0 (-3.2 ± 2.8)	52.2	44.3	68%
+0.3· τ_{med}	0.303	77.2 (+3.5 ± 2.4)	66.9 (+0.4 ± 1.2)	74.9 (+1.1 ± 1.9)	75.0	57.0	58.5 (-3.8 ± 3.0)	51.4	48.6	79%
+0.5· τ_{med}	0.500	77.4 (+3.6 ± 2.6)	66.6 (+0.0 ± 1.2)	72.0 (-1.7 ± 2.0)	70.6	58.3	56.0 (-6.2 ± 3.5)	50.3	47.5	73%

MedQA는 0.3에서 포화(77.2 → 77.4)하고 그 뒤로는 비용만 는다(FinQA·IFEval·math) → § 최적은 +0.3, 총 계수 ≈0.5 — weight-space 끌림이 0이 되는 계수와 일치.

표 D2. τ_{law}

uniform ck100에 더한 것	bfi6에 남은 계수	MedQA	CaseHOLD	FinQA	IFEval	IFBench	math(AIME 평균)	LCB v6	GPQA	§
(merge 전)	0	73.8	66.5	73.8	72.5	56.7	62.2	52.4	38.9	68%
+0.1· τ_{law}	0.026	71.9 (-1.9 ± 2.3)	67.5 (+1.0 ± 1.1)	75.2 (+1.4 ± 1.8)	73.4	56.7	62.1 (-0.1 ± 3.0)	50.2	40.9	68%
+0.3· τ_{law}	0.223	70.9 (-2.8 ± 2.5)	70.7 (+4.2 ± 1.1)	73.4 (-0.3 ± 2.0)	74.9	52.7	59.7 (-2.5 ± 3.1)	51.6	49.0	69%
+0.5· τ_{law}	0.500	68.4 (-5.3 ± 2.6)	73.4 (+6.8 ± 1.2)	71.6 (-2.2 ± 2.0)	71.0	57.0	59.0 (-3.2 ± 3.2)	48.8	46.0	67%

CaseHOLD는 계수에 선형으로 교사 수준(73.6)까지 오르지만(기울기 ≈ +13.8/단위; 교사–base 선형 예측 +11.5), MedQA가 같은 속도로 내려간다(≈ −10.8/단위; 선형 예측 −4.5의 2.4배) → §는 68 / 68 / 69 / 67%로 제자리. law 교사 자신의 MedQA가 63.4로 base(67.9)보다 낮다.

표 D3. 조합·변형·다른 시점

uniform ck100에 더한 것	bfi6에 남은 계수	MedQA	CaseHOLD	FinQA	IFEval	IFBench	math(AIME 평균)	LCB v6	GPQA	§
+0.3 med +0.1 law	med .301, law .091	75.3 (+1.5 ± 2.4)	68.8 (+2.3 ± 1.1)	72.8 (-1.0 ± 1.9)	74.5	58.3	58.3 (-3.9 ± 3.1)	49.3	49.1	76%
” (텐서별 정렬 비례, 임베딩 0)	-	76.7 (+2.9 ± 2.4)	68.4 (+1.9 ± 1.1)	73.9 (+0.2 ± 2.0)	74.9	57.0	56.9 (-5.3 ± 4.1)	48.8	52.3	79%

없는 행 = 평가 진행 중. 다른 시점(ck50·ck200)과 ns55322 arm의 결과는 표 5-1.

5-b. signal의 예측 vs merge 직후 실제 성능

칸 = **L 예측** / **S 예측** / **실제** (merge 전 uniform ck100 대비 점수 변화). L = 교사 샘플 NLL line search + isotonic 사상(2026-09-18 20:28 저장), S = 점수 공간 선형성 $\Sigma \lambda_{\text{eff}}$ (교사 점수 − base 점수)(21:00 저장). 둘 다 해당 결과가 나오기 전에 기록했다. OOD(math·LCB)는 S 예측 / 실제.

후보	bfi6에 실제로 남은 계수	MedQA	CaseHOLD	FinQA	IF(IFEval·IFBench 평균)	math(AIME 평균)	LCB v6
ck100 + med010	med .083	+1.6 / +0.9 / -0.9	+0.3 / -0.3 / +0.7	-0.3 / -0.7 / +0.6	-0.1 / -0.3 / -0.5	-0.7 / -3.2	-0.7 / -0.2
ck100 + med030	med .303	+3.7 / +3.5 / +3.5	+0.2 / -1.1 / +0.4	-1.3 / -2.5 / +1.1	-0.8 / -1.0 / +1.5	-2.7 / -3.8	-2.7 / -1.0
ck100 + med050	med .500	+5.3 / +5.7 / +3.6	-0.8 / -1.8 / +0.0	-10.0 / -4.1 / -1.7	-6.5 / -1.7 / -0.1	-4.4 / -6.2	-4.4 / -2.1
ck100 + law010	law .026	+0.4 / -0.1 / -1.9	+0.3 / +0.3 / +1.0	-0.1 / -0.0 / +1.4	-0.0 / +0.0 / +0.5	-0.3 / -0.1	-0.3 / -2.2
ck100 + law030	law .223	+0.9 / -1.0 / -2.8	+2.8 / +2.6 / +4.2	-0.7 / -0.3 / -0.3	-0.5 / +0.2 / -0.8	-2.6 / -2.5	-2.2 / -0.9
ck100 + law050	law .500	+0.9 / -2.2 / -5.3	+2.8 / +5.8 / +6.8	-5.4 / -0.6 / -2.2	-1.1 / +0.5 / -0.6	-5.9 / -3.2	-4.8 / -3.6
ck100 + med030-law010	med .301 + law .091	+3.5 / +3.0 / +1.5	+0.5 / -0.1 / +2.3	-5.0 / -2.6 / -1.0	-0.9 / -0.9 / +1.8	-3.7 / -3.9	-3.5 / -3.1

in-domain 4열의 평균 절대 오차: L 2.2점, S 1.6점 (완료된 후보 7개 기준). 쌍체 95% CI 반쪽은 MedQA ±2.3, CaseHOLD ±1.1, FinQA ±1.9라 이보다 작은 차이는 잡음.

6. signal 비교와 권고 (v2 — med·law 용량-반응 완료, 조합-변형 일부 진행 중)

표 C2. 측정된 signal의 비교

signal	필요한 것	"어느 도메인"	"얼마나"	간섭·OOD 비용	판정
W1. 갱신- τ 정렬 (cos, 부호 일치율) = 끌림	ckpt만 (63모델 GPU 4분)	학습 중 감쇠 여부로 구분됨(med·law-tau 비감쇠). 절대 크기는 도메인 간 비교 불가	끌림이 0이 되는 총 계수(med $\approx$ 0.5)가 § 기준 최적 merge량(+0.3)과 일치. 단, 자기 도메인 점수의 최적은 아님(끌림 $\approx$ 0인 ns55322에 med를 더 넣으면 MedQA는 +2.4 더 오르나 § 순이익은 +3으로 무의). 추정에 여러 arm 또는 merge 전후 2회 측정이 필요	직접 주지 않음(평형점에 간섭이 이미 반영됨)	"얼마나"의 기준점으로 채택
W2. OLS 투영 계수·속도	"	학습이 τ_d 방향으로 공급하는 속도 → 필요한 step 수(if 260 / law 3,700 / tau 4,900 / med 83,000)	-	bf16 반올림 손실 실측에 사용	보조 지표
W3. 부분공간 에너지 · SAR	" + SVD	대비 약함(SAR 자기 0.88-0.92 vs 타 0.86-0.88)	-	-	채택 안 함
G. 방향도함수 $\langle -\nabla \text{NLL}_d, \tau_j \rangle$	교사 샘플 48개/도메인, backward 1회(도메인당 약 2 GPU-분)	도메인 간 비교 가능한 단위. 감쇠율 med 25% · tau 37% · law 62% · fin 75% · if 90%	1차 정보뿐 — 곡률 큰 방향(IF)에서 과잉	$\tau_{\text{law}} \rightarrow \text{MedQA}$ 의 부호를 틀림(NLL은 개선 예측, 실제 -10.8 /단위)	"어느 도메인"용으로 채택
L. 교사 샘플 NLL line search (stochastic rounding)	교사 샘플 96개/도메인, forward만(후보당 약 4 GPU-분)	자기 probe 이득으로 직접 순위: $\lambda=0.3$ 에서 med -224 · tau -200 · law -99 · fin -18 · IF +256	자기 probe 최적 λ^* 는 과대(med ≥ 0.5 인데 벤치마크는 0.3에서 포화). isotonic 사상을 붙이면 0.5에서 꺾이는 방향은 맞하나 크기 과장(FinQA -10 예측 / 실제 -1.8)	학습된 도메인의 간섭을 과대 예측, $\tau_{\text{law}} \rightarrow \text{MedQA}$ 부호 틀림	"어느 도메인"으로 채택
S. 점수 공간 선형성 Σ_λ (교사 점수 $- \text{base}$ 점수)	교사 평가 점수표(추가 측정 0)	학생 상태를 모름 → 단독 사용 불가	선형 구간의 기울기를 맞춤(med 0.3: $+3.5$ / $+3.4$, law 0.5: $+5.8$ / $+6.9$). 포화는 못 봄(med 0.5: $+5.7$ / $+3.6$)	부호는 맞하나 크기는 부정확($\tau_{\text{law}} \rightarrow \text{MedQA}$ -2.2 / -5.4 , math -2.6 / -3.8)	기울기·비용의 1차 추정으로 채택

in-domain 예측의 평균 절대 오차(완료된 ck100 후보 기준): L + isotonic 2.2점, S 1.6점. 생체 95% CI 반폭: MedQA ± 2.3 , CaseHOLD ± 1.1 , FinQA ± 1.9 , AIME 평균 ± 3 , § ± 7 .

권고

- 어느 도메인: 세 계열이 같은 답을 낸다 — 자기 probe line search 이득이 뚜렷하고(L), 끌림·1차 이득이 학습 중 감쇠하지 않는(W·G) 도메인 = med·law·tau. fin·IF는 학습이 스스로 해결하고, IF는 τ_{if} 를 더하면 오히려 나빠진다(SR line search +256@0.3).
- 얼마나 — med: uniform ck100에서 +0.3(총 계수 $\approx$ 0.5). § 68% → 79%(학습 100 step과 동급), MedQA +3.4(± 2.3), 학습된 다른 도메인 무손상, 비용 math -3.8 (± 3.1) · LCB -1.0 . +0.5는 MedQA가 더 오르지 않고(77.4) FinQA·IFEval·math만 내려가 § 73%. +0.1은 효과 없음(bf16에 0.083만 남고 § 68%).
- 얼마나 — law: CaseHOLD는 +0.5에서 교사 수준(73.4)에 달지만 MedQA를 같은 속도로 깎아(68.4) §로는 순이익이 없다. law를 우선할 때만 넣고, med와 함께 넣는다(+0.3 med +0.1 law: MedQA +1.5 · CaseHOLD +2.3 · § 76%).
- 언제: 같은 merge의 직후 이득은 이를수록 크고(§ ck50 +9 → ck100 +8 → ck200 +4), OOD 손상도 이를수록 크다(LCB ck50 -8.4 / ck100 -3.1 / ck200 -4.0). 끌림·line search 이득이 아직 큰 중반(ck100 부근)이 절충점.
- 어떻게: fp32 master weight에서 merge하거나 stochastic rounding으로 저장한다. bf16 ckpt에 round-to-nearest로 더하면 작은 merge가 사라진다(law 0.1 → 0.026, RL 교사 0.3 → 0.09). "조금씩 여러 번"보다 "대상 도메인에 한 번에 충분히"가 맞다 — 0.1 이하의 merge는 이득이 없고 OOD 비용은 이미 발생한다(med 0.1: math -3.2 ± 2.8).
- 기각된 것: 임베딩 제외는 init의 코드 모드 붕괴를 막지 못했다(LCB 2.8 vs 1.7). "끌림 0 = 자기 도메인 최적"도 기각 — 끌림 0은 다도메인 순이익의 평형점이다.

아직 열려 있는 것

- 진행 중인 평가: 조합(+0.3 med +0.3 law, +tau 0.2, 전 교사 +0.3), if 0.3 · fin 0.3, 임베딩 제외 2중, stochastic rounding 3중.
- merge 후 MOPD를 재개했을 때 이득이 유지·확대되는지, τ_{law} 가 깎은 MedQA를 학습이 복구하는지는 재지 않았다(4노드 × 약 9시간/100 step) — 사용자 결정 사항.
- tau 도메인은 성능 측정에서 제외했다(line search상 tau도 merge 대상: $\lambda=0.3$ 에서 -200).