

MOPD Phase 3 Trajectories

Qwen3-4B-OT3 · phase 3-3 arm별 성능 궤적(merge init → ck50 → … → ck200)과 현재 최종 비교 · 2026-09-18 10:31 기준 · 사용자 요청(09-18 10:30)에 대한 답

요청 항목과 처리

- merge 직후(init)부터 ckpt별 성능 전부:** 2-dom(r20/40/60/80) merged init 4개와 5-dom merged init 3개(uniform·mix33211·ns55322)는 학습 전 13벤치 평가가 없어 방금 제출했습니다(job 578140-578146). 2-dom의 r20/r40/r60 ck50 평가는 어젯밤 취소 후 재제출되지 않아 비어 있었고 함께 제출했습니다(578147-578149). 결과가 오면 이 표의 '-' 칸이 채워집니다(표는 tmp/phase3/all_evals_phase3.json 덤프에서 재생성).
- tau2 single OPD 4개 ckpt의 tau2 telecom:** 578150-578153으로 제출(ck50/100/150/200, 공식 프롬프트·stock parser·T=1.0, 약 \$12-16/ckpt).
- 보고 형식:** 이후 PDF로 제공(이 문서). 표 규칙은 그대로(벤치 1개 = 열 1개, base·teacher 행, §, ↓ 열 분리).

5-dom base init은 왜 느린가

늦게 시작한 것이 아닙니다. 577259는 09-17 20:37에 시작해(uniform 577270은 20:52) 13.8시간 동안 74 step, 즉 **651 s/step**이고 uniform은 같은 시간에 140 step(332 s/step)입니다. 원인은 init 자체입니다. OT3 base로 시작한 학생은 5개 도메인 프롬프트(특히 tau2)에 대해 완성 길이가 평균 4.9-7.2k 토큰(잘림 4-7%)인 반면 merge init 학생은 2.1-3.3k(잘림 2% 미만)이라, 128 prompts/update의 롤아웃 생성과 교사 prefill(요청당 9.5-10.6k 토큰, 2.9-3.5 s; uniform은 6.7k 토큰, 2.3 s)이 약 2배 걸립니다. 같은 현상이 tau2 단일 OPD(OT3 init, 380-450 s/step, 길이 5-8k)에서도 있었고, 학습이 진행되면서 길이가 줄면(현재 ~4.1k) step 시간도 줄어듭니다. 노드 이상은 아닙니다(n046-054·058·197 정상). 이 속도면 ck200은 09-19 새벽입니다.

읽는 법 (현재까지)

- 2-dom grid:** ck100 → ck150에서 §2는 r20 85 → 83%, r40 98 → 99%, r60 94 → 90%, r80 100 → 101%로 사실상 정체(3점 잡음 안). 즉 학습 정도는 ck100 이후 비율과 무관하게 포화했고, 비율 차이는 MedQA(r20 75.1 vs r80 79.4)와 수학·CaseHOLD 손실(비율이 높을수록 큼)에서만 남습니다. init 값이 오면 "merge만으로 얼마나 오는지 vs 학습이 더한 것"을 분리할 수 있습니다.
- 5-dom merge ratio 3중:** ck50 → ck100에서 uniform 57 → 68%, mix33211 62 → 71%, non-simplex 79 → 79%. non-simplex는 출발점이 높고(교사 KL도 초기 0.48-0.62 vs uniform 0.70-0.83) ck50에 LCB 14.5 붕괴 후 ck100에 50.0 회복. tau2 성능은 미측정이라 5도메인 §는 아직 없음.
- 최종 비교(표 1):** 4도메인 § 기준 재-merge ablation ck50 88% > phase-2 mixed-merge 87% > phase-2 uniform 80% > non-simplex ck100 79% > mix33211 ck100 71% > uniform ck100 68% > base init ck50 29%. phase-3-3 arm은 아직 ck100이라 ck200 phase-2 값과 직접 비교는 이릅니다.

표 1. 현재까지의 최종(최신 ckpt) 성능 비교 — arm마다 가장 최근에 평가된 ckpt 1개

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§(4 도메인)	§(학습 도메인)
<i>base Qwen3-4B-OT3</i>	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%	0%
<i>teacher med (SFT)</i>	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	0%	0%
<i>teacher law (SFT-only)</i>	63.4	73.6	59.6	39.4	25.0	47.5	43.3	46.7	45.8	42.5	46.0	78.7	81.5	29.6	47.9	14%	14%
<i>teacher fin (RL)</i>	68.0	60.4	75.3	32.9	24.7	53.8	45.0	53.8	50.8	49.0	16.8	82.0	78.5	33.9	52.0	20%	20%
<i>teacher IF (RL)</i>	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	18%	18%
5-dom MOPD, base init ck50	67.9	58.0	72.4	67.3	48.3	60.4	57.9	60.4	59.6	53.6	20.6	78.7	78.7	32.4	50.1	29%	29%
5-dom MOPD, uniform merge init ck100	73.8	66.5	73.8	72.5	56.7	64.2	61.2	61.2	62.2	52.4	38.9	65.0	79.5	31.5	48.4	68%	68%
5-dom MOPD, mix33211 merge init ck100	75.3	67.3	74.4	69.1	53.3	64.2	57.5	60.4	60.7	50.1	38.4	53.0	79.5	31.2	48.5	71%	71%
5-dom MOPD, non-simplex ns55322 init ck100	77.3	69.2	72.5	72.1	56.3	64.6	55.8	59.2	59.9	50.0	48.7	55.0	79.2	32.2	49.7	79%	79%
5-dom MOPD, mix-v3 SFT warm-up init (sftw2) (ck 평가 없음)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
2-dom med+IF, init med 0.2 / IF 0.8, ck150	75.1	60.4	59.7	81.1	57.3	67.5	62.1	61.2	63.6	46.8	50.5	75.3	79.7	29.9	47.5	36%	83% (med·IF)
2-dom med+IF, init med 0.4 / IF 0.6, ck150	78.6	60.0	59.3	78.2	60.0	63.8	58.8	57.1	59.9	46.4	51.1	78.3	79.9	30.0	47.5	42%	99% (med·IF)
2-dom med+IF, init med 0.6 / IF 0.4, ck150	77.4	59.0	59.6	77.8	55.0	66.2	56.2	56.7	59.7	45.1	52.8	78.0	79.6	30.4	47.9	36%	90% (med·IF)
2-dom med+IF, init med 0.8 / IF 0.2, ck150	79.4	57.5	60.6	77.1	58.7	62.9	55.4	52.5	56.9	44.3	51.6	79.0	78.8	30.4	48.5	40%	101% (med·IF)
tau2 single OPD (base init) ck150	68.3	57.8	58.2	42.7	24.0	62.9	56.2	57.5	58.9	51.2	24.9	79.0	77.7	34.8	52.5	-12%	-
재-merge ablation: 4-dom ck200 + 0.3·τ_med → MOPD ck50	78.0	70.5	74.3	77.1	57.3	64.6	57.1	57.9	59.9	52.0	49.2	77.7	79.4	31.1	48.2	88%	88%
phase-2 참조: 4-dom uniform-merge MOPD ck200	75.4	69.9	73.1	78.6	57.0	63.8	59.2	57.9	60.3	52.9	42.0	77.3	79.9	30.6	47.7	80%	80%
phase-2 참조: 4-dom mixed-merge balance-batch ck200	77.3	71.0	73.8	76.7	58.0	62.9	56.2	57.5	58.9	51.6	46.2	64.0	79.6	31.0	48.0	87%	87%

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 톨아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job). §(4 도메인)은 모든 행을 같은 4개 도메인으로 비교(2-dom arm은 law·fin을 학습하지 않아 낮음); §(학습 도메인)은 그 arm이 학습한 도메인만(2-dom = med·IF, tau2 단일 OPD는 tau2 미측정이라 -). 5-dom arm의 tau2 열은 미평가.

표 2-1. 2-dom med+IF MOPD, merge init med 0.2 / IF 0.8 — 꺾적

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§₂(med, IF)
<i>base Qwen3-4B-OT3</i>	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%
<i>teacher med (SFT)</i>	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	45%
<i>teacher IF (RL)</i>	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	58%
merged-medif-r20 (init, 학습 전) (제출 578140)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck50 (제출 578147)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck100	75.4	60.3	58.5	80.0	58.0	67.5	61.2	58.8	62.5	48.1	54.2	70.7	79.5	30.0	47.9	85%
ck150	75.1	60.4	59.7	81.1	57.3	67.5	62.1	61.2	63.6	46.8	50.5	75.3	79.7	29.9	47.5	83%
ck200 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 톨아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).

표 2-2. 2-dom med+IF MOPD, merge init med 0.4 / IF 0.6 — 꺾적

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§₂(med, IF)
<i>base Qwen3-4B-OT3</i>	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§ ₂ (med, IF)
<i>teacher med (SFT)</i>	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	45%
<i>teacher IF (RL)</i>	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	58%
merged-medif-r40 (init, 학습 전) (제출 578141)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck50 (제출 578148)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck100	78.2	59.2	59.7	77.4	61.3	67.9	56.7	60.0	61.5	47.8	50.8	75.0	79.7	30.8	48.1	98%
ck150	78.6	60.0	59.3	78.2	60.0	63.8	58.8	57.1	59.9	46.4	51.1	78.3	79.9	30.0	47.5	99%
ck200 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 몰아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).

표 2-3. 2-dom med+IF MOPD, merge init med 0.6 / IF 0.4 — 꺾적

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§ ₂ (med, IF)
<i>base Qwen3-4B-OT3</i>	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%
<i>teacher med (SFT)</i>	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	45%
<i>teacher IF (RL)</i>	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	58%
merged-medif-r60 (init, 학습 전) (제출 578142)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck50 (제출 578149)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck100	77.8	58.3	59.5	78.6	58.0	67.5	59.6	62.9	63.3	46.6	49.6	77.7	79.3	30.4	48.0	94%
ck150	77.4	59.0	59.6	77.8	55.0	66.2	56.2	56.7	59.7	45.1	52.8	78.0	79.6	30.4	47.9	90%
ck200 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 몰아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).

표 2-4. 2-dom med+IF MOPD, merge init med 0.8 / IF 0.2 — 꺾적

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§ ₂ (med, IF)
<i>base Qwen3-4B-OT3</i>	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%
<i>teacher med (SFT)</i>	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	45%
<i>teacher IF (RL)</i>	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	58%
merged-medif-r80 (init, 학습 전) (제출 578143)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck50	80.1	55.1	58.9	68.6	60.3	64.6	52.9	56.7	58.1	44.5	47.0	61.3	78.6	30.4	48.8	100%
ck100	79.7	57.1	59.3	76.5	56.3	66.7	55.8	54.6	59.0	42.7	49.1	63.0	78.6	30.4	48.7	100%
ck150	79.4	57.5	60.6	77.1	58.7	62.9	55.4	52.5	56.9	44.3	51.6	79.0	78.8	30.4	48.5	101%
ck200 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 몰아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).

표 3-1. 5-dom MOPD, uniform merge (0.2 ×5) — 꺾적

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§(4 도메인)
<i>base Qwen3-4B-OT3</i>	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%
<i>teacher med (SFT)</i>	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	0%

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 몰아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).

표 3-4. 5-dom MOPD, base init — 꺾적 (init = base 행과 동일)

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§(4 도메인)
base Qwen3-4B-OT3	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%
teacher med (SFT)	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	0%
teacher law (SFT-only)	63.4	73.6	59.6	39.4	25.0	47.5	43.3	46.7	45.8	42.5	46.0	78.7	81.5	29.6	47.9	14%
teacher fin (RL)	68.0	60.4	75.3	32.9	24.7	53.8	45.0	53.8	50.8	49.0	16.8	82.0	78.5	33.9	52.0	20%
teacher IF (RL)	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	18%
Qwen3-4B-OT3 (init = base 행)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck50	67.9	58.0	72.4	67.3	48.3	60.4	57.9	60.4	59.6	53.6	20.6	78.7	78.7	32.4	50.1	29%
ck100 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck150 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck200 (학습 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 몰아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).

표 4. tau2 single OPD (base init) — 꺾적 (tau2 telecom은 578150-578153으로 측정 중)

모델 (ckpt)	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	math(AIME 평균)	LCB v6	GPQA	HarmBench ASR↓	Sycophancy↓	TQA MC1	TQA MC2	§(4, 참고)
base Qwen3-4B-OT3	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	57.6	52.1	30.3	86.0	78.3	34.0	51.0	0%
teacher med (SFT)	79.3	58.4	52.5	34.6	21.3	54.2	46.2	46.2	48.9	43.3	47.5	73.3	78.2	30.6	49.8	0%
teacher law (SFT-only)	63.4	73.6	59.6	39.4	25.0	47.5	43.3	46.7	45.8	42.5	46.0	78.7	81.5	29.6	47.9	14%
teacher fin (RL)	68.0	60.4	75.3	32.9	24.7	53.8	45.0	53.8	50.8	49.0	16.8	82.0	78.5	33.9	52.0	20%
teacher IF (RL)	69.7	59.0	58.4	77.6	58.0	62.1	57.1	60.8	60.0	52.3	49.6	70.0	79.6	32.3	49.4	18%
Qwen3-4B-OT3 (init = base 행)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-
ck50	69.6	60.0	61.6	41.0	26.7	61.7	48.3	58.3	56.1	49.3	31.3	79.3	78.2	34.1	51.7	2%
ck100	69.1	57.8	59.7	39.6	24.3	62.5	50.4	59.2	57.4	50.5	29.4	76.0	77.9	34.1	52.2	-8%
ck150	68.3	57.8	58.2	42.7	24.0	62.9	56.2	57.5	58.9	51.2	24.9	79.0	77.7	34.8	52.5	-12%
ck200 (평가 중)	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-	-

프로토콜: 생성형 벤치 전부 T=1.0 / top_p 1.0 / top_k 비활성(= 학습 몰아웃), in-domain 26,624 토큰, IF·OOD 32,768; AIME avg@8, GPQA avg@4, 나머지 n=1; sycophancy·TruthfulQA는 log-prob. § = 표기된 도메인의 base→teacher 진행률 평균(IF = IFEval·IFBench 정규화 평균; base·교사는 같은 프로토콜의 t1-* 행). ↓ = 낮을수록 좋음(평균에 넣지 않음). 3점 이내 차이는 n=1 잡음 범위. '-' = 미측정(괄호에 제출 job).