

MOPD phase 3-4 결과 종합

Qwen3-4B-OT3 · 2026-09-20 08:19 기준 · 평가: eval_all(T=1.0, top_p 1.0) / τ²-bench v1.0.1 공식 하네스(telecom base 114 tasks, 1 trial) · τ² T=0.6은 top_p .95 / top_k 20 / max_tokens 16k

핵심 결과

- merged init MOPD가 tau2를 실제로 학습합니다.** tau 가중치를 0.8-1.0으로 올린 merge에서 출발하면 τ²가 init 10.5-14.9 → ck100에 46.5-50.0(T=0.6 기준 57.0-60.5), ck150에 최대 54.4(T=0.6 63.2)까지 오릅니다. 도구 호출도 교사 수준(대화당 5-6회)에 도달합니다. 이전 5-dom run들(tau 가중치 0.5 이하)은 200 step 뒤에도 τ² 11-16이었습니다.
- merge init의 도구 호출량이 학습 가능 여부를 가릅니다.** tau 0.5 → 대화의 1-2%만 도구를 쓰고 대화당 0.0회(씨앗 없음, MOPD 실패). tau 0.8-1.0 → 대화의 60-71%가 한 번쯤 쓰지만 대화당 1회 근처이고 대화가 43-48턴으로 늘어짐(씨앗 있음, MOPD가 이것을 5-6회로 키움). tau 1.0 + 나머지 0.2 → 교사 수준(5.4-5.6회)이지만 다른 도메인이 무너짐(§ 3-7%).
- 13벤치와 τ²의 최적 지점이 다릅니다.** 4도메인 진행률 §는 ck100에서 83%로 최고이고, τ²는 ck150에서 최고입니다. ck150-200 구간에서 IF가 출렁입니다(ns10-5323 IFEval 73.9 → 56.7 → 59.3).
- sean teacher는 tau2 성능은 같고 다른 도메인 손상이 적습니다.** merge 후 τ²는 두 교사가 잡음(±4) 안에서 동일한데, sean 쪽이 IF(ns85323 IFEval 52.7 vs 47.9)와 코드(tau10-o02 LCB 45.7 vs 26.9)를 덜 깎습니다. ns55322에서는 § 54% vs 47%입니다. 도구 호출 임계점도 sean 쪽이 조금 이릅니다(ns85323에서 대화 66% vs 37%).
- SFT warm-up은 세 목표를 동시에 맞추는 구성을 찾았습니다.** law 2.2M + med 120M + tau 90M의 **s10a ck156**이 CaseHOLD 66.0 / MedQA 73.6 / τ² 17.5입니다. tau 80M(s10b)과 70M(s10c)도 목표 안이지만 도구 호출이 거의 사라지고(대화당 0.1-0.7회) 빈 응답 실패가 늘어납니다(5-8건).
- warm-up의 tau2 점수는 도구 없이도 오릅니다.** τ² 15-20 구간의 warm-up ckpt들은 대화당 도구 호출이 0.1-1.4회입니다. 즉 목표 밴드를 맞춘 warm-up은 MOPD가 키울 씨앗이 merge init(1.0-1.3회)과 비슷하거나 더 적습니다. warm-up을 MOPD init으로 쓸 경우 이 점이 관건입니다.

1. tau2 교사 두 종

tau2 교사	τ² T=1.0	τ² T=0.6	AReal 프롬프트	도구 쓴 대화	대화당 호출	대화당 턴	학습
Noah teacher (동료 packed32, 현행 기본)	57.0	71.1	50.9	99%	9.0	19.2	2 epoch · 342 step · 5e-6 cosine
sean teacher (우리 sft_tau2_3ep ck390)	64.9	69.3	63.2	100%	6.9	17.4	3 epoch · 390 step · 5e-6 cosine
같은 run ck260 (2 epoch)	57.9	67.5	63.2	-	-	-	-
base Qwen3-4B-OT3	9.6	-	-	-	-	-	-

2. merged init 비교 — sean teacher vs Noah teacher (MOPD 없음)

merge (tau/med/law/fin/if)	교사	도구 쓴 대화	대화당 호출	대화당 턴	τ²	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	LCB v6	GPQA	HarmB↓	Syco↓	TQA	§
base Qwen3-4B-OT3	-	-	-	-	9.6	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	52.1	30.3	86.0	78.3	51.0	0%
ns55322 .5/.5/.3/.2/.2	Noah	1%	0.0	20.5	9.6	-	-	-	-	-	-	-	-	-	-	-	-	-	47%*
ns55322 .5/.5/.3/.2/.2	sean	2%	0.0	17.8	11.4	76.7	67.6	68.4	55.3	34.7	59.6	47.1	49.2	47.8	49.6	51.0	79.0	51.2	54%
ns85323 .8/.5/.3/.2/.3	Noah	37%	0.5	48.3	10.5	75.0	67.7	66.3	47.9	29.3	51.2	45.8	45.8	43.1	44.4	46.0	79.2	51.4	42%
ns85323 .8/.5/.3/.2/.3	sean	66%	1.1	45.4	13.2	73.7	67.9	66.0	52.7	32.3	51.7	43.8	45.0	44.4	44.9	43.7	78.5	51.5	42%
ns10-5323 1.0/.5/.3/.2/.3	Noah	71%	1.3	47.7	14.9	73.5	67.6	64.8	42.0	28.3	52.1	40.0	40.0	42.1	43.8	35.7	78.7	51.7	34%
ns10-5323 1.0/.5/.3/.2/.3	sean	60%	1.0	42.9	13.2	73.4	67.0	64.4	45.7	32.7	45.8	39.6	42.9	42.4	48.5	38.0	78.0	51.7	34%
tau10-o02 1.0/.2/.2/.2/.2	Noah	98%	5.6	18.0	52.6	66.9	62.3	64.3	34.0	23.3	43.3	40.4	42.5	26.9	33.5	36.3	78.1	52.5	3%
tau10-o02 1.0/.2/.2/.2/.2	sean	100%	5.4	17.5	50.9	66.0	63.9	65.9	35.1	23.0	52.5	49.6	43.3	45.7	37.6	38.3	77.8	52.6	7%

* Noah ns55322의 § 47%는 이전 스왑 값(13벤치 태그가 달라 개별 열 생략). 도구 호출은 τ² 평가가 만든 rollout 114개 대화에서 집계. HarmB/Syco는 낮을수록 좋음.

3. merged init MOPD 궤적 (Noah teacher, 5-dom 128/upd, 200 step, 4 nodes)

모델	도구 쓴 대화	대화당 호출	대화당 턴	τ^2 T=1.0	τ^2 T=0.6	MedQA	CaseHOLD	FinQA	IFEval	IFBench	AIME24	AIME25	AIME26	LCB v6	GPQA	HarmB↓	Syco↓	TQA	§
base Qwen3-4B-OT3	-	-	-	9.6	-	67.9	62.1	60.8	37.5	25.0	61.2	53.3	58.3	52.1	30.3	86.0	78.3	51.0	0%
ns10-5323 init (학습 전)	71%	1.3	47.7	14.9	-	73.5	67.6	64.8	42.0	28.3	52.1	40.0	40.0	42.1	43.8	35.7	78.7	51.7	34%
ns10-5323 ck50	98%	5.4	16.8	35.1	49.1	76.4	68.5	74.2	67.3	58.7	61.2	47.1	53.8	48.9	44.4	53.0	78.7	51.3	77%
ns10-5323 ck100	99%	6.1	17.2	50.0	57.0	78.3	68.9	74.2	73.9	54.3	62.1	53.3	52.5	50.0	46.0	54.0	78.8	51.0	83%
ns10-5323 ck150	100%	6.0	17.7	54.4	63.2	77.1	68.7	74.7	56.7	42.3	60.8	54.2	60.0	49.7	44.1	52.7	78.7	50.7	71%
ns10-5323 ck200	100%	11.8	21.8	39.5	-	77.9	69.4	73.6	59.3	46.3	58.8	53.8	53.3	49.7	42.6	53.3	78.8	50.8	75%
ns85323 init (학습 전)	37%	0.5	48.3	10.5	-	75.0	67.7	66.3	47.9	29.3	51.2	45.8	45.8	43.1	44.4	46.0	79.2	51.4	42%
ns85323 ck50	-	-	-	32.5	44.7	77.8	68.5	70.4	56.9	39.7	63.3	53.3	56.2	49.0	48.7	55.0	79.0	50.6	64%
ns85323 ck100	96%	5.5	19.0	46.5	60.5	77.1	69.6	73.8	75.4	56.7	63.3	53.8	56.7	51.1	44.4	58.0	79.0	50.5	83%
ns85323 ck150	94%	5.1	18.0	43.0	65.8	76.1	69.3	72.8	73.0	55.0	60.8	55.8	59.2	51.6	43.8	49.7	79.3	50.3	77%
ns85323 ck200	99%	5.7	18.1	44.7	-	78.0	69.3	75.0	67.3	52.0	61.7	56.7	59.2	50.4	42.4	52.0	79.4	50.3	82%

4. SFT warm-up 예산 탐색 (전체)

run	교사	law	med	tau	step	ckpt	CaseHOLD	MedQA	τ^2	빈 응답	도구 쓴 대화	대화당 호출
목표 (사용자)	-	-	-	-	-	-	67 근처	72 이상	15~20	0	-	-
r2a	Noah	10.5M	60M	16M	84	ck42	68.5	67.6	·	·	-	-
						ck63	70.4	69.5	·	·	-	-
						ck84	70.4	68.5	0.9	107	-	-
r2b	Noah	21.0M	75M	24M	120	ck60	71.2	70.2	·	·	-	-
						ck90	71.5	68.3	·	·	-	-
						ck120	72.6	71.5	7.9	92	-	-
r3a	Noah	3.5M	70M	20M	92	ck46	64.6	68.7	·	·	-	-
						ck69	66.5	69.4	·	·	-	-
						ck92	67.3	71.3	·	·	-	-
r3b	Noah	5.5M	70M	20M	96	ck48	67.8	68.3	·	·	-	-
						ck72	68.5	69.8	·	·	-	-
						ck96	69.0	69.8	·	·	-	-
r4a	Noah	1.3M	25M	110M	132	ck66	64.9	67.7	·	·	-	-
						ck99	65.5	68.8	·	·	-	-
						ck132	66.4	68.0	31.6	0	-	-
r4b2	Noah	1.5M	40M	97M	136	ck68	65.4	69.8	·	·	-	-
						ck102	65.9	68.4	·	·	-	-
						ck136	65.8	70.0	14.0	0	-	-
r6a	Noah	2.2M	90M	150M	236	ck118	66.4	71.6	·	·	-	-
						ck177	66.8	71.4	·	·	-	-
						ck236	66.8	72.9	45.6	0	-	-
r6b	Noah	2.2M	90M	181M	268	ck134	66.1	71.4	·	·	-	-
						ck201	67.3	71.6	·	·	-	-
						ck268	67.1	73.6	57.0	0	-	-
r7a	Noah	2.2M	90M	100M	188	ck94	65.7	72.4	14.9	3	-	-
						ck141	66.7	72.1	23.7	0	-	-
						ck188	66.1	73.2	23.7	0	70%	2.0
r8a	Noah	2.2M	90M	90M	180	ck90	65.9	70.5	16.7	16	-	-
						ck135	65.3	71.8	15.8	1	-	-
						ck180	66.3	71.2	19.3	1	-	-
r8b	Noah	2.2M	70M	80M	148	ck74	65.7	71.7	14.0	9	-	-
						ck111	66.2	71.4	15.8	1	-	-
						ck148	66.2	71.7	16.7	1	41%	0.6
r9b	Noah	2.2M	100M	100M	196	ck98	65.4	71.3	17.5	10	-	-
						ck147	66.1	72.3	21.1	1	-	-

run	교사	law	med	tau	step	ckpt	CaseHOLD	MedQA	τ^2	빈 응답	도구 쓴 대화	대화당 호출
r9a	Noah	2.2M	120M	100M	216	ck196	65.3	74.4	25.4	2	-	-
						ck108	65.2	72.5	18.4	13	-	-
						ck162	66.7	74.7	20.2	2	68%	2.1
s9b	sean	2.2M	100M	100M	196	ck216	66.1	73.5	26.3	0	75%	2.1
						ck98	66.3	71.6	19.3	5	-	-
						ck147	66.2	70.6	19.3	4	-	-
s9a	sean	2.2M	120M	100M	216	ck196	66.6	71.6	21.9	1	-	-
						ck108	65.5	72.2	16.7	3	-	-
						ck162	66.1	73.9	19.3	3	74%	2.0
s10a	sean	2.2M	120M	90M	208	ck216	66.1	73.4	26.3	1	78%	2.4
						ck104	65.2	72.2	14.9	17	8%	0.1
						ck156	66.0	73.6	17.5	4	54%	1.0
s10b	sean	2.2M	120M	80M	196	ck208	66.7	74.5	22.8	1	63%	1.4
						ck98	64.2	73.4	16.7	23	-	-
						ck147	65.5	73.2	18.4	8	38%	0.6
s10c	sean	2.2M	120M	70M	188	ck196	64.7	73.2	18.4	5	40%	0.7
						ck94	65.1	70.3	15.8	35	-	-
						ck141	65.1	70.9	15.8	8	15%	0.2
						ck188	66.0	72.4	16.7	7	11%	0.1

모든 run: batch 32 × 32k packing (1 step ≈ 1.05M tokens), lr 1e-5 cosine, warmup 5%, 4-node(r2-r4는 1-node). 초록 배경 = 세 목표 동시 충족, 빈 응답 = 첫 assistant 턴이 비어 하네스가 실패 처리한 대화 수(114개 중).